

RAPPORT DU PROJET FINALE DE PROGRAMATION DATA SCIENCE



Université
Amadou Mahtar Mbow

**Auteur:
Mamadou Aliou SOW**

**Profs:
Pr Amadou Dahirou GUEYE
Mrs Papa Assane DIOP**

PLAN

- **INTRODUCTION**
- **DONNE ET PREPARATION**
- **ANALYSE EXPLORATOIRE**
- **ANALYSE AVEC RSTUDIO**
- **VISUALISATION**
- **MODEL PREDICTIF**
- **LIMITE ET DISCUSSION DU MODEL**
- **CONCLUSION**

INTRODUCTION

La Data Science permet d'exploiter les données afin d'en extraire des informations utiles et de faciliter la prise de décision.

Dans ce projet, nous allons analyser les données de 1000 étudiants à partir de différentes informations telles que les heures d'étude, les absences, les notes, la participation aux TD/TP et l'utilisation des réseaux sociaux.

Nous commencerons par nettoyer et préparer les données, puis nous réaliserons une analyse exploratoire accompagnée de visualisations avec Python. Une partie de l'analyse sera également réalisée avec R/RStudio. Enfin, nous utiliserons un modèle de Machine Learning pour tenter de prédire la réussite ou l'échec des étudiants.

-Objectif : L'objectif est donc d'identifier les principaux facteurs associés à la réussite et de déterminer s'il est possible de repérer les étudiants susceptibles de rencontrer des difficultés.

-Problème: Peut-on analyser les facteurs qui influencent la réussite des étudiants et identifier ceux qui sont susceptibles de rencontrer des difficultés ?

1-DONNES ET PREPARATION

1.1-Presentation du jeu de donne:

A-Volumetrie et caracteristique generale:

Le jeu de données initial se présente sous la forme d'un fichier brut au format CSV (Comma-Separated Values). Les premiers indicateurs de dimensionnalité extraits à l'aide de la bibliothèque Pandas révèlent la structure suivante :

- **Nombre d'observations (lignes) : 1 003 lignes** (incluant 3 doublons introduits volontairement pour l'évaluation de la phase de nettoyage).
- **Nombre de variables (colonnes) : 14 colonnes** représentant les caractéristiques académiques, démographiques et comportementales des étudiants.
- **Nature des données :** Il s'agit de **données synthétiques** simulées spécifiquement pour ce projet pédagogique au sein de l'UFR STA de l'Université Amadou Mahtar Mbow.

B-Le type des variable:

L'examen des types de données via la méthode `.info()` de Pandas permet de classifier les 14 variables en trois grandes familles de types de données :

- Variables de type Float (6) : `heures_etude`, `note_cc`, `note_examen`, `moyenne`, `reseaux_sociaux`, `participation_td`.

- Variables de type Integer (3) : id_etudiant, age, absences.
- Variables de type String / Object (5) : sexe, filiere, niveau, internet, resultat.

```
Data columns (total 14 columns):  
#      Column      Non-Null Count  Dtype  
---  -  
0     id_etudiant    1003 non-null    int64  
1     age             1003 non-null    int64  
2     sexe            1003 non-null    str  
3     filiere          1003 non-null    str  
4     niveau          1003 non-null    str  
5     heures_etude     1000 non-null    float64  
6     absences         1003 non-null    int64  
7     note_cc          1000 non-null    float64  
8     note_examen      1003 non-null    float64  
9     moyenne          1003 non-null    float64  
10    internet         1001 non-null    str  
11    reseaux_sociaux  1003 non-null    float64  
12    participation_td  1001 non-null    float64  
13    resultat         1003 non-null    str  
dtypes: float64(6), int64(3), str(5)
```

1.2-Netoyage et preparation des donnees

- Cette étape constitue la fondation de notre projet (Semaine 1). Elle vise à transformer le fichier brut contenant des anomalies en une base saine et exploitable pour les analyses statistiques et les modèles de Machine Learning.

A-Recherche et traitement des valeur manquante

L'analyse initiale de complétude révèle que notre jeu de données souffre d'un taux important de données manquantes (NaN) sur plusieurs colonnes stratégiques :


- **heures_etude** : **29** % de valeurs manquantes.
- **note_cc** : **29** % de valeurs manquantes.
- **internet** : **19** % de valeurs manquantes.
- **participation_td** : **19** % de valeurs manquantes.

Pour comprendre la structure de ces absences, nous avons généré un dendrogramme via la bibliothèque spécialisée `missingno`. La visualisation de cet arbre hiérarchique (`msno.dendrogram`) montre que les variables s'associent de manière isolée. Il n'existe aucune corrélation de valeurs manquantes entre les variables, ce qui indique que les données sont manquantes de façon aléatoire.

Conformément aux consignes de préparation et aux types de variables, la stratégie d'imputation globale suivante a été appliquée :

- **Variables quantitatives (heures_etude, note_cc, participation_td)** : Remplacement des valeurs manquantes par la **médiane** (ou la moyenne) globale de chaque colonne afin de ne pas biaiser la distribution avec des valeurs extrêmes.
- **Variable qualitative (internet)** : Remplacement par le **mode** (la valeur la plus fréquente, à savoir "Oui"), s'agissant d'une variable textuelle.

Note critique : Pour éviter toute fuite de données (Data Leakage), ces calculs de tendances centrales auraient idéalement dû être calculés uniquement sur un échantillon d'apprentissage (Train) avant d'être appliqués sur le Test. Cependant, pour respecter la chronologie des livrables de ce projet, ce traitement a été appliqué de manière globale en Semaine 1.



B-Recherche et suppression des doublons:

- La présence de lignes strictement identiques fausse les analyses statistiques et donne un poids artificiel à certaines observations lors de l'entraînement des modèles.
L'application de la fonction `.duplicated` sous Pandas a permis de détecter précisément 3 **lignes de doublons** . Ces lignes redondantes ont été éliminées définitivement à l'aide de la méthode `.drop_duplicates()`.

C-Encodage des variables catégorielles:

Les algorithmes de Machine Learning ne pouvant traiter que des valeurs numériques, une phase d'encodage a été indispensable pour nos 5 variables qualitatives :

- **Encodage Label (LabelEncoder)** : Appliqué aux variables binaires (possédant deux modalités ou moins) pour les convertir en 0 ou 1.
 - `sexe` : Encodé en 0 ou 1.
 - `internet` : Encodé en 0 ("Non") ou 1 ("Oui").
 - `resultat` : Encodé en 0 ("Réussi") ou 1 ("Échec").
- **Encodage One-Hot (OneHotEncoder)** : Appliqué aux variables possédant plus de deux modalités pour éviter d'induire une hiérarchie d'ordre artificielle entre les valeurs. Cette méthode crée une nouvelle colonne binaire (0 ou 1) pour chaque modalité.
 - `niveau` → création de `niveau_L1`, `niveau_L2`, `niveau_L3`.
 - `filiere` → création de `filiere_Data Science`, `filiere_Gestion`, `filiere_Informatique`, `filiere_Mathematiques`.

À l'issue de cette première semaine de traitement, la base de données ne contient plus aucune valeur manquante ni aucun doublon, et toutes ses variables sont prêtes pour la phase d'analyse visuelle.

2-ANALYSE EXPLORATOIRE

Cette section synthétise la description statistique de notre population étudiante afin de dresser un premier panorama des performances globales et catégorielles.

2.1-Analyse des performances globales

L'étude descriptive des notes de la population universitaire met en exergue les métriques suivantes :

- **Moyenne générale globale : 14,00 / 20**
- **Meilleure moyenne enregistrée : 20,00 / 20**
- **Plus faible moyenne enregistrée : 6,62 / 20**

Interprétation : Le niveau global des apprenants au sein de l'établissement est satisfaisant, comme en témoigne la moyenne générale centrale de 14,00/20. Toutefois, l'analyse de l'étendue des notes révèle un écart massif de **13,38 points** entre l'étudiant le plus performant et celui en grande difficulté. Cette forte amplitude est l'indice d'une hétérogénéité prononcée et confirme l'existence d'un groupe d'étudiants en situation de décrochage scolaire sévère, nécessitant une identification automatisée.

2.2-Analyse des performances par filière

La répartition des moyennes générales selon l'orientation choisie par les étudiants s'établit comme suit :

- **Data Science** : 14,11 / 20
- **Informatique** : 13,99 / 20
- **Mathématiques** : 13,99 / 20
- **Gestion** : 13,84 / 20

Interprétation : Les moyennes calculées par filière sont extrêmement homogènes et gravitent toutes rigoureusement autour de 14/20. La filière *Data Science* se positionne très légèrement en tête (14,11/20), tandis que la filière *Gestion* affiche la moyenne la plus basse (13,84/20). Ces écarts minimes et non significatifs tendent à prouver que le niveau de sélection ou les critères d'évaluation sont équivalents d'un département à l'autre.

2.3-Analyse selon le sexe et le niveau d'étude

- **Analyse par genre** : Les étudiants rattachés au groupe encodé 1 présentent une moyenne générale très légèrement supérieure (**14,13 / 20**) vis-à-vis du groupe encodé 0 (**13,87 / 20**). Cet écart de seulement 0,26 point indique que le genre ne constitue pas un facteur discriminant ou explicatif majeur de la réussite universitaire.
- **Analyse par niveau d'étude** : Les résultats scolaires affichent une progression constante tout au long du cursus de Licence :
 - **Licence 1 (L1)** : 13,93 / 20
 - **Licence 2 (L2)** : 13,95 / 20
 - **Licence 3 (L3)** : 14,14 / 20

Interprétation : Cette hausse progressive de la moyenne de la L1 à la L3 s'explique de manière classique par deux phénomènes combinés : l'effet de sélection (les étudiants en situation d'échec ou de réorientation quittent le cursus durant les deux premières années) et l'effet d'adaptation (les étudiants de L3 maîtrisent mieux les méthodologies de travail universitaire).

2.4-Répartition de la variable cible et justification du projet

L'analyse de la variable à prédire resultat met en lumière la répartition suivante :

- **Classe 0 (Taux de réussite) : 95,4 %**
- **Classe 1 (Taux d'échec) : 4,6 %**

Interprétation : La base de données est caractérisée par un **fort déséquilibre de classes** (*imbalanced dataset*). La classe majoritaire englobe la quasi-totalité des étudiants validant leur année, tandis que la classe minoritaire cible (4,6 %) représente les profils en échec. Ce faible pourcentage rend la détection manuelle de ces étudiants extrêmement complexe mais cruciale. C'est ce déséquilibre qui légitime l'usage d'algorithmes de Data Science capables de traquer spécifiquement ces 4,6 % de profils à risque afin de déclencher des alertes pédagogiques précoces.


3-VISUALISATION ET INTERPRETATION

Cette partie s'appuie sur les livrables graphiques générés à l'aide de Matplotlib et Seaborn pour valider visuellement nos premières hypothèses.

3.1-Distribution des moyennes générales (Histogramme):


L'histogramme de la distribution des notes met en scène une courbe centrée sur la valeur de **14,00 / 20**, adoptant la forme d'une cloche asymétrique à gauche. Si le cœur de la population se concentre dans l'intervalle de succès compris entre 11 et 17 sur 20, la queue de distribution s'étirant vers la gauche matérialise la minorité d'étudiants en difficulté dont la moyenne s'effondre jusqu'à la limite critique de **6,62 / 20**.

Distribution des moyennes générales des étudiants




3.2-Comparaison des filières (Barplot):

Le diagramme en barres confirme visuellement la proximité des performances inter-filières. La filière *Data Science* atteint le sommet visuel (14,11) tandis que la *Gestion* ferme la marche (13,84). L'intégration des moustaches d'erreur (intervalles de confiance) montre un chevauchement total des barres, prouvant graphiquement l'absence d'un "effet filière" majeur sur la note finale.




3.3-Dispersion des notes selon le sexe (Boxplot):

La boîte à moustaches met en évidence des lignes médianes quasi-alignées pour les groupes encodés 0 et 1 autour de la note 14, confirmant la faible variabilité globale selon le genre. Néanmoins, l'écart interquartile (la hauteur de la boîte) et l'étirement de la moustache inférieure du groupe 0 indiquent une dispersion des notes légèrement plus prononcée vers les valeurs basses, concentrant une proportion infime mais critique de profils à risque.




3.4-Impact du travail personnel (Scatter plot):

Le nuage de points mettant en relation les heures d'étude et la moyenne générale affiche une trajectoire linéaire positive très marquée. À mesure que le volume horaire de travail hebdomadaire progresse, la moyenne générale s'élève. On remarque une segmentation colorimétrique absolue : les points associés aux étudiants en échec (classe 1) s'agglutinent exclusivement dans le quadrant inférieur gauche du graphique, confirmant qu'un faible investissement horaire est un indicateur précurseur direct de l'échec.



3.5-mpact de l'absentéisme (Scatter plot):


À l'inverse du graphique précédent, le nuage de points liant les absences à la moyenne dessine une corrélation linéaire négative extrêmement nette. L'accumulation des absences entraîne une dégradation systématique et brutale de la moyenne générale de l'étudiant. Passé un seuil critique d'absences, le basculement vers la classe d'échec devient quasi-inévitable, faisant de l'assiduité un pilier fondamental de la réussite.



3.6-Analyse globale des intercorelation:

La carte de chaleur permet de hiérarchiser mathématiquement les relations linéaires du dataset. Plusieurs faits saillants se détachent :

- Une corrélation positive maximale entre note_cc, note_examen et moyenne.
- Un fort coefficient positif entre heures_etude et moyenne.
- Un coefficient négatif sévère reliant absences et moyenne.
- Une corrélation négative modérée montrant l'impact délétère d'un temps excessif sur les reseaux_sociaux au détriment de la note d'examen.



4-PREDICTION

Cette section formalise l'évaluation statistique de notre modèle d'Arbre de Décision, entraîné sur un échantillon de test isolé comprenant 200 observations.

4.1. Analyse de la matrice de confusion

La confrontation des prédictions de l'arbre de décision avec les observations réelles du jeu de test produit la matrice suivante :

- **Vrais Négatifs (VN) : 191** étudiants correctement classés en réussite.
- **Vrais Positifs (VP) : 9** étudiants correctement interceptés en situation d'échec.
- **Faux Positifs (FP) : 0** étudiant classé à tort en échec.
- **Faux Négatifs (FN) : 0** étudiant en échec non détecté par le modèle.

Analyse des erreurs : La diagonale secondaire dédiée aux erreurs d'aiguillage (FP et FN) est strictement nulle. D'un point de vue purement mathématique, l'arbre réalise un sans-faute absolu sur l'échantillon de test.

4.2. Analyse des métriques de classification

L'examen détaillé du rapport de classification vient chiffrer cette performance parfaite :


- **Précision (Classe 1 - Échec) : 1.00 (100 %)**. Chaque alerte d'échec déclenchée par l'algorithme est fiable à 100 %.
- **Rappel (Classe 1 - Échec) : 1.00 (100 %)**. L'algorithme capture l'intégralité des 9 étudiants réellement en situation d'échec.
- **Score F1 (Classe 1 - Échec) : 1.00 (100 %)**. La moyenne harmonique parfaite confirme que le déséquilibre initial des classes (4,6 % d'échecs) a été totalement maîtrisé par l'arbre, sans dégrader la justesse des prédictions.
- **Exactitude globale (Accuracy) : 1.00 (100 %)**. Le taux de prédictions correctes sur le bloc de test atteint la perfection.

4.3. Diagnostic par la courbe d'apprentissage:

La courbe d'apprentissage de notre fonction apporte un éclairage structurel important :

- **Score d'apprentissage (Train - Bleu) :** La courbe reste horizontalement soudée au score de **1.0000**, ce qui indique une mémorisation parfaite des données d'entraînement par l'arbre, quelle que soit l'échelle de l'échantillon ($\backslash(N\backslash)$).
- **Score de validation (Test - Orange) :** Débutant à **0.9825** pour un faible volume d'entraînement de 60 étudiants, la courbe progresse rapidement pour former un plateau parfait stable à **0.9987** dès l'apport de 350 observations.

L'écart (*gap*) quasiment invisible entre l'apprentissage et la validation croisée au-delà de 350 lignes traduit, dans une analyse standard, une convergence absolue du modèle et une excellente capacité de généralisation des règles mathématiques apprises.



6-LIMITES ET DISCUSSION DU MODEL

Bien que les performances de l'algorithme soient mathématiquement irréprochables, une analyse critique de Data Scientist révèle des failles conceptuelles majeures :

- **Le biais majeur de la fuite de données (*Data Leakage*)** : Cette perfection statistique (100 % de réussite) est artificielle. Elle s'explique par le maintien des variables de performance académique directe (moyenne, note_examen, note_cc) au sein de la matrice de fonctionnalités fournies au modèle. L'arbre de décision n'effectue aucun travail d'anticipation ou d'apprentissage complexe : il se borne à redécouvrir la règle déterministe et arithmétique de l'université ($\text{Moyenne} < 10 = \text{Échec}$).
- **Inutilité opérationnelle en situation réelle** : En l'état, ce modèle est inutilisable par l'administration de l'Université Amadou Mahtar Mbow. Un système d'alerte précoce efficace doit pouvoir identifier un étudiant en danger *au cours du semestre* (via ses absences ou son faible volume d'heures d'étude) afin de mettre en place une remédiation. Si le modèle requiert la saisie de la moyenne finale pour fonctionner, l'échec a déjà eu lieu et la prédiction arrive trop tard.
- **Éclipse des facteurs comportementaux** : Le poids mathématique absolu des notes dans le calcul de l'entropie de l'arbre masque et neutralise totalement l'influence des variables de comportement (absences, reseaux_sociaux, participation_td), réduisant à néant l'intérêt de leur collecte.

CONCLUSION

- Ce projet de Data Science a permis de couvrir l'intégralité de la chaîne de valeur du traitement de données. Si la phase d'exploration et de visualisation a mis en lumière l'impact indiscutable des variables comportementales (le rôle protecteur des heures d'étude face à l'effet destructeur de l'absentéisme), la phase de modélisation a quant à elle illustré un piège classique : le *Data Leakage*.
- Pour l'évolution de ce travail, nous recommandons le retrait immédiat des variables de notes (moyenne, `note_examen`, `note_cc`) et un réentraînement du modèle basé uniquement sur les données comportementales disponibles dès les premières semaines du semestre.

